

Uvod

Cilj ovog rada je analiza i primena različitih klasifikacionih algoritama nad tekstualnim skupom podataka sa ciljem razlikovanja dve klase dokumenata. Posebna pažnja posvećena je uticaju različitih reprezentacija podataka i metoda redukcije dimenzionalnosti na performanse klasifikacionih modela.

U okviru rada izvršeno je preprocesiranje podataka i njihova transformacija u oblik pogodan za primenu algoritama mašinskog učenja. Tekstualni podaci predstavljeni su pomoću TF-IDF reprezentacije, nakon čega su ispitane metode selekcije atributa pomoću χ^2 testa i redukcije dimenzionalnosti primenom TruncatedSVD metode.

Za klasifikaciju su primenjeni različiti algoritmi, uključujući Multinomial Naive Bayes, LinearSVC, K-Nearest Neighbors, Decision Tree i Logistic Regression. Performanse modela analizirane su pomoću standardnih evaluacionih metrika, kao što su Accuracy, Precision, Recall i F1-score, a najbolji modeli dodatno su upoređeni pomoću ROC krivih i AUC vrednosti.

Cilj analize je da se utvrdi koji klasifikacioni algoritam i koja reprezentacija podataka daju najbolje rezultate za dati skup tekstualnih podataka, kao i da se ispita uticaj smanjenja broja atributa na kvalitet klasifikacije.

1. Opis skupa podataka

U ovom projektu korišćen je **Farm Ads** skup podataka namenjen binarnoj klasifikaciji tekstualnih oglasa. Skup sadrži oglase prikupljene sa dvanaest internet stranica koje se bave temama vezanim za domaće životinje. Za svaki oglas dostupni su tekst oglasa (*ad creative*) i tekst odredišne stranice (*landing page*), pri čemu su u tekst uključene i informacije iz naslova i zaglavlja HTML stranica.

Zadatak klasifikacije je da se, na osnovu tekstualnog sadržaja oglasa, odredi da li je oglas **prihvaćen** ili **odbijen** od strane vlasnika sadržaja. Ciljna promenljiva ima dve vrednosti:

- **1** – prihvaćen oglas,
- **-1** – odbijen oglas.

U radu je korišćena tekstualna verzija skupa podataka farm-ads, u kojoj svaki red predstavlja jedan oglas. Prvi element u redu predstavlja oznaku klase, dok ostatak reda sadrži tekst oglasa. Reči koje potiču iz samog oglasa označene su prefiksom **ad-**, dok su informacije preuzete sa odredišne stranice označene odgovarajućim prefiksima, kao što su **title-** i **header-**.

U skupu podataka izvršeno je osnovno preprocesiranje teksta, koje uključuje uklanjanje zaustavnih reči (*stop words*) i svođenje reči na njihove osnovne oblike (*stemming*). Zbog toga ove faze preprocesiranja nisu ponavljane u okviru ovog rada.


- Primer jednog zapisa iz skupa podataka:

1 ad-animal ad-animal ad-wild ad-sa ...

Prvi element predstavlja oznaku klase, dok ostatak reda čine tokeni koji opisuju sadržaj oglasa i povezane veb stranice.

2. Osnovna analiza skupa podataka

Nakon učitavanja podataka izdvojene su oznake klase i tekstualni sadržaj oglasa, a zatim je formiran DataFrame sa kolonama **label** i **text**. Izvršena je osnovna analiza skupa podataka kako bi se dobio uvid u njegovu strukturu.



Skup podataka sadrži ukupno **4143 oglasa**, od čega je **2210 prihvaćenih (53,34%)**, a **1933 odbijena (46,66%)**. Može se uočiti da su klase približno ravnomerno zastupljene, zbog čega se skup može smatrati gotovo izbalansiranim.

3. Vektorizacija

Tokom osnovne analize skupa podataka utvrđeno je da tekstovi sadrže 54 877 različitih tokena. Međutim, veliki broj tih tokena pojavljuje se veoma retko, često samo u jednom dokumentu, zbog čega imaju malu vrednost za proces klasifikacije i nepotrebno povećavaju dimenzionalnost podataka.

Zbog toga je za vektorizaciju korišćena metoda CountVectorizer sa parametrom `min_df=2`, čime su iz vokabulara uklonjeni svi tokeni koji se pojavljuju u manje od dva dokumenta. Na ovaj način smanjen je broj atributa, uklonjen deo šuma u podacima i formiran reprezentativniji vokabular za dalju obradu.

Nakon primene CountVectorizer-a formirana je TF matrica dimenzija $3314 \times 24\,307$, u kojoj svaki red predstavlja jedan dokument, a svaka kolona jedan token iz vokabulara. Vrednosti u matrici predstavljaju broj pojavljivanja odgovarajućeg tokena u dokumentu.

Dobijena matrica čuva se u sparse formatu u memoriji, pri čemu se beleže samo nenulte vrednosti, jer većina tokena nije prisutna u većini dokumenata. Ovakav način predstavljanja značajno smanjuje zauzeće memorije, jer se većina tokena ne pojavljuje u većini dokumenata.

U narednom koraku na ovu matricu primenjuje se TF-IDF transformacija. Pri tome se ne menja broj redova i kolona niti raspored nenulatih elemenata, već se broj pojavljivanja tokena zamenjuje njihovim TF-IDF težinama, koje uzimaju u obzir ne samo učestalost tokena u posmatranom dokumentu, već i njegovu zastupljenost u celom skupu podataka. Na taj način često zastupljeni tokeni dobijaju manju težinu, dok tokeni koji bolje razlikuju dokumente dobijaju veću težinu.

Primer dela TF-IDF matrice nakon transformacije tekstualnih podataka:

	accent	accept	accessory	account	accurate	action	ad	ad-aatb	ad-agent	ad-agriculture	ad-bunny	ad-call	ad-com	ad-company
0	0.000	0.000	0.000	0.000	0.00	0.00	0.000	0.000	0.000	0.000	0.000	0.067	0.000	0.000
1	0.035	0.000	0.019	0.000	0.01	0.01	0.000	0.000	0.000	0.000	0.016	0.000	0.000	0.000
2	0.000	0.034	0.000	0.013	0.00	0.00	0.000	0.037	0.000	0.000	0.000	0.000	0.000	0.000
3	0.000	0.000	0.000	0.000	0.00	0.00	0.004	0.000	0.013	0.019	0.000	0.000	0.004	0.011
4	0.000	0.000	0.000	0.000	0.00	0.00	0.000	0.000	0.000	0.000	0.000	0.000	0.029	0.000

4. Vizuelizacija

Koristimo TruncatedSVD kako bismo vizuelno predstavili naše podatke u dvodimenzionalnom i trodimenzionalnom prostoru. TruncatedSVD ne vrši izbor postojećih karakteristika, već formira novi prostor karakteristika pomoću latentnih komponenti. Dobijene komponente predstavljaju linearne kombinacije originalnih 24 307 TF-IDF karakteristika i kreirane su tako da zadrže što veći deo informacije sadržane u početnim podacima.

Na ovaj način svaki dokument se iz prostora velikog broja dimenzija projektuje u prostor sa manjim brojem dimenzija. Na primer, u 2D prikazu svaki dokument je predstavljen pomoću dve vrednosti koje predstavljaju njegove koordinate po prvoj i drugoj latentnoj komponenti, dok se informacija iz originalnog teksta i dalje zadržava kroz kombinaciju svih početnih karakteristika.


- **Analiza dobijenih grafika**

Na prikazima se može uočiti značajno preklapanje između klasa, odnosno veliki broj prihvaćenih i odbijenih oglasa nalazi se u istom delu prostora. To pokazuje da prve dve ili tri latentne komponente nisu dovoljne za jasno razdvajanje klasa.



Iako je broj dimenzija značajno smanjen, ovakva reprezentacija gubi deo informacija iz originalnog skupa podataka. Zbog toga se za potrebe klasifikacije ispituje veći broj komponenti kako bi se pronašao odgovarajući balans između smanjenja dimenzionalnosti i očuvanja informacija.

Pored glavne koncentracije podataka, mogu se uočiti i manje izolovane grupe tačaka. One predstavljaju dokumente koji imaju drugačiju strukturu u odnosu na većinu podataka i koji sadrže specifične kombinacije karakteristika koje ih izdvajaju u prostoru latentnih komponenti.

2D vizuelizacija



3D vizuelizacija



5. Redukcija dimenzionalnosti

Nakon formiranja TF-IDF matrice, svaka reč iz vokabulara predstavlja jedan atribut. Kod tekstualnih podataka broj atributa može biti veoma veliki, što povećava memorijske zahteve, vreme treniranja modela i može negativno uticati na sposobnost generalizacije. Zbog toga se primenjuju metode redukcije dimenzionalnosti.

U ovom radu biće korišćena dva različita pristupa:

- **Selekcija atributa (Feature Selection)** – zadržavaju se samo najinformativniji originalni atributi korišćenjem **SelectKBest** metode sa χ^2 (Chi-square) testom.
- **Redukcija atributa (Feature Extraction)** – originalni atributi transformišu se u manji broj novih atributa korišćenjem **TruncatedSVD** metode.

Za obe metode ispitan je veći broj vrednosti parametara kako bi se analiziralo kako različiti nivoi redukcije utiču na očuvanje informacija i kasnije performanse klasifikacionih modela.

Takodje pravimo listu broja komponenti za TruncatedSVD zato što želimo da vidimo:

- kako raste objašnjena varijansa,
- kako različiti nivoi redukcije utiču na strukturu podataka i kasnije performanse klasifikacionih modela,
- gde dalje povećavanje broja komponenti više nema značajan efekat.

Pored same redukcije dimenzionalnosti, kod TruncatedSVD važno je analizirati i koliko informacije ostaje sačuvano nakon projekcije u novi prostor.. Kasnije cemo nacrtati i graf. Iz tog grafa cemo moci da opravdamo izbor broja komponenti.

5.1. χ^2 selekcije atributa

- SelectKBest je algoritam koji bira najbolje atribute.
- χ^2 je kriterijum po kome ih ocenjuje.

Nakon formiranja TF-IDF matrice izvršena je redukcija dimenzionalnosti primenom metode SelectKBest sa χ^2 (Chi-square) testom. Ova metoda predstavlja tehniku selekcije atributa, pri čemu se ne kreiraju novi atributi, već se iz originalnog skupa zadržavaju samo oni koji imaju najveću povezanost sa ciljnom klasom.

Za svaki atribut izračunava se χ^2 statistika koja meri koliko je prisustvo tog atributa povezano sa klasom dokumenta (prihvaćen ili odbijen oglas). Atributi sa većim χ^2 vrednostima smatraju se informativnijim za klasifikaciju i zadržavaju se u redukovanom skupu podataka.

Kako bi se ispitao uticaj broja odabranih atributa na performanse klasifikacije, eksperiment je sproveden za više vrednosti parametra k, pri čemu je broj zadržanih atributa iznosio:

$$k = \{10, 100, 500, 1000, 3000, 5000, 10000, 20000\}.$$

Za svaku vrednost parametra formirane su nove trening i test matrice, koje će u nastavku rada biti korišćene za treniranje i evaluaciju klasifikacionih modela. Istovremeno je izračunat procenat redukcije dimenzionalnosti u odnosu na originalnu TF-IDF matricu.

Rezultati primene χ^2 selekcije za različite vrednosti parametra k prikazani su u tabeli:

	k	Broj atributa	Zadržano (%)	Redukcija (%)
0	10	10	0.04	99.96
1	100	100	0.41	99.59
2	500	500	2.06	97.94
3	1000	1000	4.11	95.89
4	3000	3000	12.34	87.66
5	5000	5000	20.57	79.43
6	10000	10000	41.14	58.86
7	20000	20000	82.28	17.72

5.2. TruncatedSVD

Za razliku od χ^2 selekcije atributa, koja zadržava samo najznačajnije postojeće karakteristike iz originalne TF-IDF reprezentacije, metoda TruncatedSVD vrši transformaciju podataka u novi prostor manje dimenzionalnosti. Pri tome se originalni atributi kombinuju i formiraju nove latentne komponente, gde svaka komponenta predstavlja određenu kombinaciju početnih TF-IDF karakteristika i nosi deo informacije sadržane u originalnim podacima.

Zbog različitog načina rada, uočena je razlika u vremenu izvršavanja ove dve metode. χ^2 selekcija je računski jednostavnija jer svaki atribut posmatra nezavisno i samo određuje njegovu povezanost sa ciljnom klasom, nakon čega se zadržavaju atributi sa najboljim vrednostima. Nasuprot tome, TruncatedSVD zahteva složenije numeričke proračune jer vrši dekompoziciju matrice i pronalazi nove latentne komponente. Zbog toga je njegovo izvršavanje sporije i zahteva više računarskih resursa.

Kako bi se ispitao uticaj broja komponenti na očuvanje informacija, testirane su različite vrednosti parametra *components*:

components = [10, 50, 100, 200, 300, 500, 700, 1000]


Za svaku vrednost izvršena je transformacija trening i test skupa, a zatim je izračunata ukupna objašnjena varijansa pomoću atributa *explained_variance_ratio_*. Ova vrednost predstavlja procenat informacije iz originalne TF-IDF reprezentacije koji ostaje sačuvan nakon redukcije dimenzionalnosti.

Rezultati objašnjene varijanse prikazani su u tabeli. Može se uočiti da povećanje broja komponenti dovodi do očuvanja većeg dela informacije, ali istovremeno povećava dimenzionalnost novog prostora. Grafički prikaz dodatno pokazuje da se najveći rast objašnjene varijanse ostvaruje pri manjim brojevima komponenti, dok se kasnijim povećanjem njihovog broja dobija sve manji dodatni doprinos.

Rezultati TruncatedSVD redukcije za različit broj latentnih komponenti:

	Broj komponenti	Objašnjena varijansa (%)	Rast varijanse (%)
0	10	15.99	NaN
1	50	37.02	21.03
2	100	48.59	11.57
3	200	60.25	11.66
4	300	67.27	7.02
5	500	76.69	9.42
6	700	83.39	6.70
7	1000	90.91	7.52

Grafički prikaz očuvanja informacije u zavisnosti od broja SVD komponenti:



Dobijeni rezultati pokazuju da povećanje broja komponenti dovodi do povećanja objašnjene varijanse, odnosno da veći broj latentnih dimenzija omogućava očuvanje većeg dela informacija iz originalne TF-IDF reprezentacije.

Sa samo 10 komponenti zadržava se približno 16% informacije, dok se sa 500 komponenti zadržava oko 77% informacije. Međutim, iako veći broj komponenti omogućava očuvanje većeg dela informacije, istovremeno povećava računarsku zahtevnost algoritma i dimenzionalnost ulaznih podataka za kasnije modele.

Može se uočiti da se najveći porast objašnjene varijanse ostvaruje pri manjim brojevima komponenti, dok kasnije povećanje donosi sve manje dodatne informacije u odnosu na povećanje računarskih zahteva. Zbog toga je pri primeni TruncatedSVD potrebno pronaći odgovarajući kompromis između smanjenja dimenzionalnosti i očuvanja informacija.

6.Primena modela

Nakon završene pripreme podataka i redukcije dimenzionalnosti, izvršena je klasifikacija pomoću više različitih algoritama. Cilj primene različitih modela je poređenje njihovih performansi i analiza uticaja različitih reprezentacija podataka na uspešnost klasifikacije.

U radu su korišćeni sledeći klasifikacioni modeli:

1. Multinomial Naive Bayes
2. Linear Support Vector Machine (LinearSVC)
3. Decision Tree

4. K-Nearest Neighbors (KNN)
5. Logistic Regression

Za svaki model analizirano je ponašanje nad različitim reprezentacijama podataka:

- originalnom TF-IDF matricom,
- matricom nakon χ^2 selekcije atributa,
- matricama dobijenim primenom TruncatedSVD redukcije.

Performanse modela procenjene su pomoću Accuracy, Precision, Recall i F1-score metrika.

6.1. Multinomial Naive Bayes

6.1.1. Primena modela nad originalnom TF-IDF reprezentacijom

Multinomial Naive Bayes klasifikator prvo je primenjen nad originalnom TF-IDF reprezentacijom podataka, bez prethodne redukcije dimenzionalnosti.

Model ostvaruje Accuracy vrednost od 87.7% i F1-score od 89.3%. Posebno visoka vrednost Recall metrike (96.4%) za pozitivnu klasu pokazuje da model uspešno prepoznaje većinu oglasa koji pripadaju ovoj klasi. Međutim, nešto niža Precision vrednost (83.2%) ukazuje na postojanje većeg broja lažno pozitivnih klasifikacija.

Analizom matrice konfuzije može se uočiti da je 86 negativnih primera pogrešno klasifikovano kao pozitivno, dok je svega 16 pozitivnih primera klasifikovano kao negativno. Dobijeni rezultati pokazuju da model ima tendenciju da češće bira pozitivnu klasu, što dovodi do visokog odziva, ali nešto manje preciznosti.

6.1.2. Primena modela nakon χ^2 selekcije atributa

Kako bi se ispitao uticaj broja izabranih atributa na performanse Multinomial Naive Bayes klasifikatora, izvršena je χ^2 selekcija atributa za različite vrednosti parametra k .

Testirane su vrednosti:

$$k = \{10, 100, 500, 1000, 3000, 5000, 10000, 20000\}.$$

Za svaku vrednost parametra formiran je novi trening i test skup sa odgovarajućim brojem izabranih atributa, nakon čega je izvršena evaluacija modela.

Dobijeni rezultati pokazuju da veoma mali broj atributa nije dovoljan za kvalitetnu klasifikaciju. Za vrednost $k=10$ model ostvaruje najlošije rezultate, sa Accuracy vrednošću od 72.3% i F1-score vrednošću od 79.0%. Iako je Recall visok (98.0%), niska Precision vrednost ukazuje na veliki broj lažno pozitivnih klasifikacija. Ovo pokazuje da premali broj karakteristika ne sadrži dovoljno informacija za pouzdano razlikovanje klasa.

Sa povećanjem broja atributa dolazi do poboljšanja performansi, jer model dobija pristup većem broju relevantnih karakteristika.

Najbolji rezultati ostvareni su za vrednosti $k=3000$, 10000 i 20000 , pri čemu model postiže približno iste performanse. Accuracy iznosi oko 88.1%, dok se F1-score nalazi u opsegu od 89.6% do 89.7%.

Dalje povećanje broja atributa nakon $k=3000$ ne donosi značajno poboljšanje rezultata. Vrednosti $k=5000$, 10000 i 20000 daju veoma slične performanse, što ukazuje da dodatne karakteristike ne doprinose značajno klasifikaciji.

Na osnovu dobijenih rezultata izabrana je konfiguracija sa $k=3000$ atributa za dalja poređenja. Ova vrednost predstavlja dobar kompromis između broja atributa i kvaliteta modela, jer omogućava značajno smanjenje dimenzionalnosti uz zadržavanje gotovo maksimalnih performansi.

Za izbor optimalne vrednosti parametra k korišćena je F1-score metrika, jer predstavlja ravnotežu između Precision i Recall metrike i uzima u obzir različite vrste grešaka koje model može napraviti. Sama Accuracy vrednost nije dovoljna kao kriterijum izbora, jer modeli sa sličnom tačnošću mogu imati različite odnose između lažno pozitivnih i lažno negativnih klasifikacija.

6.1.3. Primena modela nakon TruncatedSVD redukcije

Multinomial Naive Bayes klasifikator nije primenjen nakon TruncatedSVD redukcije dimenzionalnosti.

Razlog za to je način rada ovog algoritma. Multinomial Naive Bayes pretpostavlja da ulazni atributi predstavljaju nenegativne vrednosti, kao što su frekvencije pojavljivanja reči ili TF-IDF težine. Nakon TruncatedSVD transformacije originalna TF-IDF reprezentacija se projektuje u novi prostor latentnih komponenti, pri čemu pojedinačne vrednosti komponenti mogu biti negativne.

Dobijene latentne komponente nemaju direktnu interpretaciju kao količine pojavljivanja reči, zbog čega ovakva reprezentacija nije odgovarajuća za Multinomial Naive Bayes klasifikator. Iz tog razloga ovaj model nije kombinovan sa TruncatedSVD redukcijom.

6.2. LinearSVC

6.2.1. Primena modela nad originalnom TF-IDF reprezentacijom

Primenom LinearSVC klasifikatora nad originalnom TF-IDF reprezentacijom podataka, dobijeni rezultati pokazuju veoma dobre performanse modela, sa Accuracy vrednošću od 90.7% i F1-score vrednošću od 91.5%. Visoka Recall vrednost (93.9%) pokazuje da model uspešno prepoznaje veliki broj primera pozitivne klase, dok Precision vrednost od 89.2% ukazuje da je većina pozitivnih predikcija ispravna.

Analizom performansi po klasama može se uočiti da model uspešno klasifikuje obe klase. Za klasu -1 ostvaruje Precision od 92.6% i Recall od 87.1%, dok za klasu 1 postiže viši Recall od 93.9% i F1-score od 91.5%. To pokazuje da model bolje prepoznaje pozitivne primere, ali da deo negativnih primera klasifikuje kao pozitivne.

Dobijeni rezultati pokazuju da LinearSVC veoma uspešno klasifikuje tekstualne podatke predstavljene TF-IDF reprezentacijom, što potvrđuje da je linearni SVM pogodan za rad sa visokodimenzionalnim i retkim skupovima podataka.

6.2.2. Primena modela nakon χ^2 selekcije atributa

Za analizu uticaja broja izabranih atributa na performanse LinearSVC klasifikatora primenjena je χ^2 selekcija atributa sa različitim vrednostima parametra k .

Rezultati pokazuju da mali broj atributa dovodi do značajnog pada performansi. Za $k=10$ model ostvaruje Accuracy od 75.6% i F1-score od 80.9%, što ukazuje da ovakav broj karakteristika nije dovoljan za uspešnu klasifikaciju.

Povećanjem broja atributa dolazi do poboljšanja performansi, jer model raspolaže većom količinom relevantnih informacija. Najbolji rezultat ostvaren je za $k=20000$, gde model postiže Accuracy od 90.8% i F1-score od 91.6%.

Ipak, razlika u odnosu na konfiguraciju sa $k=3000$ je veoma mala, dok je broj atributa višestruko veći. Zbog toga je za dalja poređenja izabrana konfiguracija sa $k=3000$, jer predstavlja bolji odnos između performansi i smanjenja dimenzionalnosti.

6.2.3. Primena modela nakon TruncatedSVD redukcije

Uticaj broja latentnih komponenti na performanse LinearSVC klasifikatora analiziran je primenom TruncatedSVD redukcije dimenzionalnosti.

Rezultati pokazuju da se sa povećanjem broja komponenti u početku poboljšavaju performanse modela. Kod manjeg broja komponenti, kao što su 10 i 50, dolazi do gubitka značajnog dela informacija iz originalne TF-IDF reprezentacije, što rezultuje slabijim performansama.

Najbolji rezultat ostvaren je sa 500 komponenti, gde model postiže Accuracy od 90.1% i F1-score od 90.9%. Dalje povećanje broja komponenti na 700 i 1000 ne donosi dodatno poboljšanje, već rezultati ostaju približno isti ili blago opadaju.

Na osnovu dobijenih rezultata izabrana je konfiguracija sa 500 TruncatedSVD komponenti, jer omogućava značajno smanjenje dimenzionalnosti uz zadržavanje visokog kvaliteta klasifikacije.

6.3. KNN

6.3.1. Primena modela nad originalnom TF-IDF reprezentacijom

KNN klasifikator primenjen je nad originalnom TF-IDF reprezentacijom podataka, pri čemu je analiziran uticaj broja najbližih suseda na performanse modela. Testirane su različite vrednosti parametra *neighbors* kako bi se utvrdilo kako promena broja suseda utiče na kvalitet klasifikacije.

Dobijeni rezultati pokazuju da manje vrednosti parametra daju najbolje performanse. Za vrednosti $k=3$ i $k=5$ model ostvaruje najbolje rezultate, sa Accuracy vrednošću od 88.5% i F1-score vrednošću od 89.7%. U odnosu na vrednost $k=1$, povećanje broja suseda dovodi do blagog poboljšanja, jer odluka modela postaje stabilnija i manje zavisi od pojedinačnih primera iz trening skupa.

Sa daljim povećanjem broja suseda dolazi do postepenog pada performansi. Za veće vrednosti parametra ($k=10, 15$ i 20) smanjuju se Accuracy i F1-score vrednosti, što ukazuje da uključivanje većeg broja suseda dovodi do previše opšte odluke i gubitka lokalnih karakteristika podataka.

Na osnovu dobijenih rezultata, za dalja poređenja izabrana je konfiguracija sa $k=3$ najbliža suseda, jer ostvaruje najbolji F1-score rezultat uz najmanji broj suseda koji daje stabilnu klasifikaciju.

6.3.2. Primena modela nakon χ^2 selekcije atributa

Uticaj selekcije atributa na performanse KNN klasifikatora analiziran je primenom χ^2 metode sa različitim vrednostima parametra k . Za svaku vrednost broja izabranih atributa dodatno je ispitano više vrednosti hiperparametra *neighbors*.

Rezultati pokazuju da optimalan broj suseda zavisi od broja izabranih atributa. Promena reprezentacije podataka utiče na raspored instanci u prostoru, zbog čega se menja i optimalna konfiguracija KNN klasifikatora.

Najslabije performanse ostvarene su za $k=10$ atributa, gde model postiže Accuracy od 77.0% i F1-score od 81.4%. Ovakav rezultat pokazuje da veoma mali broj odabranih karakteristika ne sadrži dovoljno informacija za uspešnu klasifikaciju.

Povećanjem broja atributa dolazi do poboljšanja performansi, a najbolji rezultat ostvaruje konfiguracija sa $k=20000$ atributa i $\text{neighbors}=7$, gde model postiže Accuracy od 85.8% i F1-score od 87.5%.

Međutim, potrebno je primetiti da vrednost $k=20000$ predstavlja zadržavanje gotovo kompletnog originalnog skupa atributa (24307 atributa). To znači da χ^2 selekcija u ovom slučaju nije dovela do značajnog smanjenja dimenzionalnosti, već je modelu bilo potrebno zadržati veliki broj karakteristika kako bi ostvario najbolje rezultate.

Za dalja poređenja izabrana je konfiguracija sa $k=20000$ atributa i $\text{neighbors}=7$, jer ostvaruje najveću F1-score vrednost među svim ispitanim kombinacijama parametara.

Za razliku od LinearSVC modela, koji zadržava visoke performanse i nakon značajnije redukcije broja atributa, KNN pokazuje veću osetljivost na uklanjanje karakteristika. Ovo ukazuje da su za ovaj model odnosi između instanci u prostoru atributa značajni i da agresivna selekcija atributa može dovesti do gubitka važnih informacija.

6.3.3. Primena modela nakon TruncatedSVD redukcije

Za analizu uticaja TruncatedSVD transformacije na performanse KNN klasifikatora ispitan je različit broj latentnih komponenti. Za svaku vrednost broja komponenti dodatno je analizirano više vrednosti parametra *neighbors*.

Dobijeni rezultati pokazuju da se performanse modela poboljšavaju povećanjem broja latentnih komponenti. Pri malom broju komponenti dolazi do gubitka većeg dela informacija iz originalne TF-IDF reprezentacije, što negativno utiče na klasifikaciju.

Najbolji rezultat ostvaruje konfiguracija sa 700 TruncatedSVD komponenti i 5 najbližih suseda, pri čemu model postiže Accuracy od 89.0% i F1-score od 89.9%. Dalje povećanje broja komponenti na 1000 ne donosi dodatno poboljšanje performansi.

U poređenju sa χ^2 selekcijom atributa, TruncatedSVD omogućava KNN klasifikatoru da postigne bolje rezultate uz značajno manji broj dimenzija. Latentna reprezentacija dobijena SVD transformacijom uspešnije očuvava odnose između dokumenata koji su važni za rad KNN algoritma.

Na osnovu dobijenih rezultata, za dalja poređenja izabrana je konfiguracija sa 700 TruncatedSVD komponenti i $n_neighbors=5$, jer ostvaruje najveću F1-score vrednost među svim ispitanim kombinacijama parametara.

6.4. Decision Tree

6.4.1. Primena modela nad originalnom TF-IDF reprezentacijom

Kod Decision Tree klasifikatora analiziran je uticaj hiperparametra *max_depth*, koji određuje maksimalnu dubinu stabla odlučivanja i utiče na složenost modela. Male vrednosti ovog parametra mogu dovesti do nedovoljne složenosti modela i pojave *underfitting*-a, dok veoma velike vrednosti mogu izazvati prekomerno prilagođavanje trening podacima (*overfitting*).

Rezultati pokazuju da povećanje dubine stabla u početku dovodi do poboljšanja performansi modela. Za manje vrednosti parametra (*max_depth*=3 i 5) model ostvaruje slabije rezultate, što ukazuje da stablo nije dovoljno kompleksno da opiše obrasce prisutne u podacima.

Najbolje performanse ostvarene su za vrednosti *max_depth*=10 i *max_depth*=15, pri čemu F1-score u oba slučaja iznosi 85.8%. Daljim povećanjem dubine stabla na *max_depth*=20, kao i uklanjanjem ograničenja dubine (*max_depth=None*), dolazi do smanjenja performansi. Ovakvo ponašanje ukazuje da previše složena stabla postaju sklona memorisanju specifičnosti trening skupa (*overfitting*), zbog čega slabije generalizuju na nepoznatim podacima.

S obzirom na to da konfiguracije sa *max_depth*=10 i *max_depth*=15 ostvaruju iste performanse, za dalju analizu izabrana je vrednost *max_depth*=10, jer predstavlja jednostavniji model koji postiže isti kvalitet klasifikacije uz manju složenost.

6.4.2. Primena modela nakon χ^2 selekcije atributa

Uticaj χ^2 selekcije atributa na performanse Decision Tree klasifikatora analiziran je korišćenjem različitih vrednosti parametra *k*. Za svaku vrednost broja izabranih atributa ispitano je više vrednosti hiperparametra *max_depth*.

Dobijeni rezultati pokazuju da se optimalna vrednost dubine stabla menja u zavisnosti od broja izabranih atributa. Kod manjih vrednosti parametra *k* najbolje rezultate postižu stabla bez ograničenja dubine (*max_depth=None*), dok se kod većeg broja atributa kao optimalne izdvajaju manje dubine stabla. Ovo pokazuje da izbor reprezentacije podataka utiče na potrebnu složenost modela.

Najslabiji rezultati ostvareni su za *k*=10 atributa, gde model postiže Accuracy od 76.7% i F1-score od 81.4%. Ovakav rezultat potvrđuje da veoma mali broj karakteristika nije dovoljan za opis složenih obrazaca u tekstualnim podacima.

Povećanjem broja atributa dolazi do poboljšanja performansi, a najbolji rezultat ostvaruje konfiguracija sa *k*=500 atributa i *max_depth=None*. Ova konfiguracija postiže Accuracy od 86.1% i F1-score od 87.3%.

Zanimljivo je da dalje povećanje broja atributa ne dovodi do poboljšanja performansi. Nakon vrednosti *k*=500 dolazi do blagog opadanja metrika, što ukazuje da zadržavanje većeg broja karakteristika ne doprinosi dodatnoj informaciji za Decision Tree model, već može povećati složenost prostora u kome se vrši klasifikacija.

U poređenju sa originalnom TF-IDF reprezentacijom, χ^2 selekcija sa 500 atributa omogućava značajno smanjenje dimenzionalnosti uz očuvanje dobrih performansi modela i zbog toga je ta konfiguracija izabrana za dalja poređenja.

6.4.3. Primena modela nakon TruncatedSVD redukcije

Uticaj TruncatedSVD redukcije dimenzionalnosti na performanse Decision Tree klasifikatora analiziran je kroz različit broj latentnih komponenti. Za svaku vrednost broja komponenti ispitano je više vrednosti hiperparametra *max_depth*.

Rezultati pokazuju da povećanje broja TruncatedSVD komponenti u početku dovodi do poboljšanja performansi modela. Pri veoma malom broju komponenti (10 i 50) sačuvan je manji deo informacija iz originalne TF-IDF reprezentacije, što dovodi do slabijih rezultata klasifikacije.

Sa povećanjem broja komponenti performanse modela postepeno rastu, a najbolji rezultat ostvaruje konfiguracija sa 700 komponenti i *max_depth*=20. Ova konfiguracija postiže Accuracy od 85.6% i najveću F1-score vrednost od 86.7%.

Dalje povećanje broja komponenti na 1000 ne donosi dodatno poboljšanje, već dolazi do blagog pada F1-score vrednosti. Ovo ukazuje da dodatne latentne komponente ne sadrže dovoljno novih informacija koje bi značajno unapredile klasifikaciju.

Može se uočiti da optimalna dubina stabla zavisi od korišćene reprezentacije podataka. Dok se kod originalne TF-IDF matrice najbolji rezultati dobijaju sa manjom dubinom stabla, nakon TruncatedSVD transformacije potrebna je veća složenost modela kako bi se iskoristile informacije iz latentnog prostora.

Na osnovu dobijenih rezultata za dalja poređenja izabrana je konfiguracija sa 700 TruncatedSVD komponenti i *max_depth*=20, jer ostvaruje najveću F1-score vrednost među svim ispitanim kombinacijama parametara.

6.5. Logistic Regression

6.5.1. Primena modela nad originalnom TF-IDF reprezentacijom

Logistic Regression klasifikator primenjen je nad originalnom TF-IDF reprezentacijom podataka, bez dodatne redukcije broja atributa. Dobijeni rezultati pokazuju da model ostvaruje visoke performanse, sa Accuracy vrednošću od 89.9% i F1-score vrednošću od 90.9%.

Visoka vrednost Recall metrike (95.5%) pokazuje da model uspešno prepoznaje veliki broj primera pozitivne klase, odnosno da propušta mali broj stvarnih pozitivnih primera. Precision vrednost od 86.8%

ukazuje da postoji određeni broj lažno pozitivnih klasifikacija, ali da je većina predviđenih pozitivnih primera ispravno klasifikovana.

Analizom performansi po klasama može se uočiti da model nešto bolje prepoznaje klasu 1. Za ovu klasu ostvaruje Recall od 95.5% i F1-score od 90.9%, što pokazuje da uspešno pronalazi većinu pozitivnih primera. Kod klase -1 model ostvaruje veću Precision vrednost (94.2%), ali nešto niži Recall (83.5%), što znači da su predviđanja ove klase uglavnom pouzdana, ali da određeni broj primera klase -1 klasifikuje kao klasu 1.

Dobijeni rezultati pokazuju da Logistic Regression predstavlja odgovarajući model za klasifikaciju tekstualnih podataka sa velikim brojem TF-IDF atributa, jer uspešno koristi linearnu povezanost između karakteristika i ciljne klase.

6.5.2. Primena modela nakon χ^2 selekcije atributa

Uticaj broja izabranih atributa na performanse Logistic Regression klasifikatora analiziran je primenom χ^2 selekcije atributa sa različitim vrednostima parametra k .

Dobijeni rezultati pokazuju da mali broj izabranih atributa dovodi do značajnog pada performansi modela. Pri najmanjoj vrednosti parametra ($k=10$) model ostvaruje najlošije rezultate, sa Accuracy vrednošću od 73.9% i F1-score vrednošću od 79.9%. Ovakav rezultat pokazuje da veoma agresivna redukcija uklanja veliki broj informacija važnih za razlikovanje klasa.

Povećanjem broja atributa dolazi do postepenog poboljšanja performansi, jer model dobija pristup većem broju relevantnih karakteristika koje doprinose klasifikaciji. Najbolji rezultat ostvaruje se za vrednost $k=5000$ atributa, gde model postiže Accuracy od 89.7% i najveću F1-score vrednost od 90.9%.

Dalje povećanje broja atributa ne donosi značajno poboljšanje performansi. Za vrednosti $k=10000$ i $k=20000$ dolazi čak do blagog pada F1-score vrednosti u odnosu na $k=5000$. Ovo ukazuje da dodatne karakteristike iznad optimalnog broja atributa ne sadrže dovoljno novih informacija koje bi poboljšale klasifikaciju, već samo povećavaju dimenzionalnost ulaznog prostora.

Na osnovu dobijenih rezultata zaključuje se da χ^2 selekcija omogućava značajno smanjenje broja atributa uz očuvanje visokih performansi modela. Za dalja poređenja izabrana je konfiguracija sa $k=5000$ atributa, jer ostvaruje najbolju F1-score vrednost uz manji broj karakteristika u odnosu na veće vrednosti parametra k .

6.5.3. Primena modela nakon TruncatedSVD redukcije

Rezultati primene TruncatedSVD redukcije na performanse Logistic Regression klasifikatora pokazuju da povećanje broja komponenti u početku dovodi do poboljšanja performansi modela. Pri malom broju

komponenti (10 i 50) model raspolaže manjom količinom informacija iz originalne TF-IDF reprezentacije, što dovodi do nižih vrednosti evaluacionih metrika.

Sa povećanjem broja komponenti model uspeva da zadrži veći deo relevantnih informacija iz originalnog prostora, zbog čega performanse postepeno rastu. Najbolji rezultat ostvaruje se za 300 TruncatedSVD komponenti, gde model postiže Accuracy od 89.7% i F1-score vrednost od 90.9%.

Nakon ove vrednosti povećanje broja komponenti ne donosi značajno poboljšanje. Za vrednosti 500, 700 i 1000 komponenti rezultati ostaju približno isti, uz male oscilacije u vrednostima metrika. Ovo ukazuje da dodatne latentne komponente ne doprinose značajno klasifikaciji, već samo povećavaju dimenzionalnost novog prostora.

Na osnovu dobijenih rezultata za dalja poređenja izabrana je konfiguracija sa 300 TruncatedSVD komponenti, jer predstavlja dobar kompromis između smanjenja dimenzionalnosti i očuvanja performansi modela. Ova reprezentacija omogućava postizanje najboljeg rezultata uz značajno manji broj dimenzija u odnosu na originalnu TF-IDF matricu.

7. Najbolja konfiguracija na nivou modela

Nakon ispitivanja performansi klasifikacionih modelova nad originalnom TF-IDF reprezentacijom, kao i nad reprezentacijama dobijenim primenom χ^2 selekcije atributa i TruncatedSVD redukcije dimenzionalnosti, za svaki model izdvojena je konfiguracija koja daje najbolji odnos između kvaliteta klasifikacije i broja atributa.

Cilj ove analize je da se odredi reprezentacija podataka i odgovarajuće vrednosti parametara pri kojima svaki klasifikator ostvaruje najveću vrednost F1-score metrike, koja predstavlja osnovni kriterijum za izbor najbolje konfiguracije.

7.1. Multinomial Naive Bayes

Reprezentacija podataka	Parametar	Accuracy	Precision	Recall	F1-score
Originalni TF-IDF	-	0.877	0.832	0.964	0.893
χ^2	k = 3000	0.881	0.832	0.973	0.897
TruncatedSVD	-	-	-	-	-

Multinomial Naive Bayes ostvaruje najbolje performanse nakon primene χ^2 selekcije atributa sa 3000 odabranih karakteristika. U odnosu na originalnu TF-IDF reprezentaciju dolazi do blagog poboljšanja svih evaluacionih metrika, pri čemu se F1-score povećava sa 89.3% na 89.7%, dok se recall povećava sa 96.4% na 97.3%.

Dobijeni rezultat pokazuje da uklanjanje manje relevantnih atributa pozitivno utiče na klasifikaciju, jer model zadržava samo karakteristike koje imaju najveću povezanost sa ciljnom klasom.

TruncatedSVD reprezentacija nije korišćena za ovaj klasifikator, jer transformacijom mogu nastati negativne vrednosti atributa. Kako se Multinomial Naive Bayes zasniva na pretpostavci nenegativnih ulaznih vrednosti, ovakva reprezentacija nije odgovarajuća za ovaj model.

Kao najbolja konfiguracija za dalja poređenja izabrana je χ^2 reprezentacija sa 3000 atributa, jer omogućava postizanje najbolje F1-score vrednosti uz značajno smanjenje dimenzionalnosti u odnosu na originalnu TF-IDF matricu.

7.2. LinearSVC

Reprezentacija podataka	Parametar	Accuracy	Precision	Recall	F1-score
Originalni TF-IDF	-	0.907	0.892	0.939	0.915
χ^2	k = 3000	0.907	0.892	0.939	0.915
TruncatedSVD	500 komponenti	0.901	0.893	0.925	0.909

LinearSVC klasifikator pokazuje veoma stabilne performanse nad svim ispitanim reprezentacijama podataka. Najveća F1-score vrednost ostvarena je nakon χ^2 selekcije sa 20000 atributa i iznosi 91.6%. Međutim, u poređenju sa konfiguracijom sa 3000 atributa, razlika u performansama je zanemarljiva, dok je broj atributa višestruko veći.

Zbog toga je za dalju analizu izabrana konfiguracija sa 3000 atributa, koja ostvaruje iste vrednosti Accuracy, Precision i Recall kao originalna TF-IDF reprezentacija, uz značajno smanjenje dimenzionalnosti.

TruncatedSVD redukcija sa 500 komponenti takođe ostvaruje veoma dobre rezultate, sa F1-score vrednošću od 90.9%. Ipak, performanse su nešto slabije u odnosu na χ^2 selekciju, što pokazuje da LinearSVC uspešno koristi informacije sadržane u originalnim visokodimenzionalnim TF-IDF karakteristikama.

Za dalja poređenja izabrana je χ^2 reprezentacija sa 3000 atributa, jer predstavlja najbolji kompromis između performansi i smanjenja broja atributa.

7.3. KNN

Reprezentacija podataka	Parametri	Accuracy	Precision	Recall	F1-score
Originalni TF-IDF	n_neighbors = 3	0.885	0.862	0.934	0.897
chi ²	k = 20000, n_neighbors = 7	0.858	0.823	0.934	0.875
TruncatedSVD	700 komponenti, n_neighbors = 5	0.890	0.882	0.916	0.899

KNN klasifikator najbolje rezultate ostvaruje primenom TruncatedSVD redukcije sa 700 komponenti i 5 najbližih suseda. Ova konfiguracija postiže najveću F1-score vrednost od 89.9%, kao i najveću Accuracy vrednost od 89.0% među svim ispitanim reprezentacijama.

Originalna TF-IDF reprezentacija daje veoma slične rezultate, ali TruncatedSVD omogućava dodatno smanjenje dimenzionalnosti uz blago poboljšanje performansi. Ovo pokazuje da latentne komponente uspešno zadržavaju informacije važne za izračunavanje rastojanja između instanci.

Za razliku od toga, chi² selekcija nije dovela do poboljšanja rezultata. Najbolje performanse dobijene su tek kada je zadržano 20000 od 24307 atributa, što predstavlja skoro ceo originalni skup. To ukazuje da KNN nije pogodan za agresivnu selekciju atributa, jer uklanjanje većeg broja karakteristika negativno utiče na određivanje sličnosti između instanci.

Kao najbolja konfiguracija za dalja poređenja izabrana je TruncatedSVD reprezentacija sa 700 komponenti i 5 najbližih suseda, jer omogućava najbolje performanse uz značajno manji broj dimenzija u odnosu na originalnu reprezentaciju.

7.4. Decision Tree

Reprezentacija podataka	Parametri	Accuracy	Precision	Recall	F1-score
Originalni TF-IDF	max_depth = 10	0.831	0.778	0.957	0.858
chi ²	k = 500, max_depth = None	0.861	0.852	0.896	0.873
TruncatedSVD	700 komponenti, max_depth = 20	0.856	0.858	0.876	0.867

Decision Tree klasifikator najbolje performanse ostvaruje primenom chi² selekcije atributa sa 500 odabranih karakteristika i bez ograničenja dubine stabla (*max_depth = None*). Ova konfiguracija postiže najveću F1-score vrednost od 87.3%, kao i najveću Accuracy vrednost od 86.1% među svim ispitanim reprezentacijama podataka.

Posebno je značajno što se najbolji rezultat postiže sa svega 500 atributa, odnosno sa približno 2% originalnog skupa od 24307 atributa. Ovakav rezultat pokazuje da Decision Tree uspešno koristi najinformativnije karakteristike i da veliki broj dodatnih atributa ne doprinosi poboljšanju klasifikacije.

Naprotiv, uključivanje većeg broja atributa dovodi do blagog pada performansi, što ukazuje da selekcija relevantnih karakteristika može pozitivno uticati na generalizaciju modela.

TruncatedSVD reprezentacija sa 700 komponenti takođe ostvaruje dobre rezultate, sa F1-score vrednošću od 86.7%. Iako ova konfiguracija predstavlja poboljšanje u odnosu na originalnu TF-IDF reprezentaciju, performanse su nešto slabije u poređenju sa χ^2 selekcijom atributa. To ukazuje da Decision Tree bolje koristi informacije kada su zadržane originalne, najinformativnije karakteristike, nego kada su one transformisane u nove latentne komponente.

Na osnovu dobijenih rezultata, za dalja poređenja sa ostalim klasifikacionim modelima izabrana je konfiguracija sa **χ^2 reprezentacijom, 500 atributa i max_depth = None**. Ova konfiguracija omogućava postizanje najboljih performansi uz veoma značajno smanjenje broja atributa u odnosu na originalnu TF-IDF reprezentaciju.

7.5. Logistic Regression

Reprezentacija podataka	Parametri	Accuracy	Precision	Recall	F1-score
Originalni TF-IDF	-	0.899	0.868	0.955	0.909
χ^2	k = 5000	0.897	0.865	0.957	0.909
TruncatedSVD	300 komponenti	0.897	0.864	0.959	0.909

Logistic Regression klasifikator pokazuje veoma stabilne performanse nad svim ispitanim reprezentacijama podataka. Sve tri konfiguracije ostvaruju istu vrednost F1-score metrike od 90.9%, što ukazuje da promena broja atributa i načina reprezentacije podataka nema značajan negativan uticaj na kvalitet klasifikacije.

Originalna TF-IDF reprezentacija ostvaruje nešto veću Accuracy vrednost od 89.9%, dok χ^2 selekcija sa 5000 atributa i TruncatedSVD redukcija sa 300 komponenti postižu gotovo identične rezultate uz značajno manji broj dimenzija ulaznih podataka. Ovo pokazuje da Logistic Regression uspešno koristi i redukovane reprezentacije, pri čemu uklanjanje manje relevantnih atributa ili transformacija u latentni prostor ne dovodi do gubitka klasifikacionih performansi.

U poređenju sa χ^2 selekcijom, TruncatedSVD omogućava znatno veće smanjenje dimenzionalnosti, jer se originalni skup od 24307 atributa transformiše u svega 300 latentnih komponenti. Pri tome model zadržava istu F1-score vrednost, što pokazuje da latentna reprezentacija uspešno čuva informacije značajne za klasifikaciju.

Zbog toga je za dalja poređenja sa ostalim klasifikacionim modelima izabrana konfiguracija sa TruncatedSVD redukcijom i 300 komponenti. Ova konfiguracija predstavlja najbolji kompromis između

kvaliteta klasifikacije i smanjenja dimenzionalnosti, jer omogućava očuvanje performansi modela uz višestruko manji broj ulaznih atributa.

Dobijeni rezultati potvrđuju da je Logistic Regression robustan klasifikator za tekstualne podatke i da može ostvariti visoke performanse čak i nakon značajne redukcije dimenzionalnosti. Zbog toga predstavlja jedan od modela koji najuspešnije kombinuje kvalitet klasifikacije i efikasnost rada nad redukovanim reprezentacijama podataka.

8. Poređenje najboljih konfiguracija klasifikacionih modela

Nakon analize performansi svakog klasifikacionog modela nad različitim reprezentacijama podataka, za svaki model izdvojena je konfiguracija koja ostvaruje najveću vrednost F1-score metrike. Na ovaj način omogućeno je direktno poređenje klasifikatora i određivanje najbolje kombinacije modela, reprezentacije podataka i vrednosti parametara.

Model	Reprezentacija	Parametri	Accuracy	Precision	Recall	F1-score
Multinomial NB	χ^2	k=3000	0.881	0.832	0.973	0.897
LinearSVC	χ^2	k=3000	0.907	0.892	0.939	0.915
KNN	TruncatedSVD	700 komponenti, n_neighbors=5	0.890	0.882	0.916	0.899
Decision Tree	χ^2	k=500, max_depth=None	0.861	0.852	0.896	0.873
Logistic Regression	TruncatedSVD	300 komponenti	0.897	0.864	0.959	0.909

Na osnovu rezultata prikazanih u tabeli iznad može se uočiti da različiti klasifikacioni modeli ostvaruju najbolje performanse uz različite metode redukcije dimenzionalnosti i različite vrednosti hiperparametara. To pokazuje da ne postoji univerzalna optimalna konfiguracija koja odgovara svim klasifikatorima, već izbor reprezentacije podataka zavisi od karakteristika konkretnog algoritma.

Najveću F1-score vrednost ostvaruje LinearSVC model (0.915), nakon primene χ^2 selekcije sa 3000 atributa. Ovaj rezultat pokazuje da LinearSVC uspešno radi nad visokodimenzionalnim tekstualnim podacima i da se performanse mogu zadržati i nakon značajnog smanjenja broja atributa. Veoma blizu nalazi se Logistic Regression sa F1-score vrednošću od 0.909, pri čemu najbolje rezultate postiže nakon TruncatedSVD redukcije na 300 latentnih komponenti. To ukazuje da linearni klasifikatori mogu ostvariti veoma dobre performanse čak i nakon značajne redukcije dimenzionalnosti.


KNN najbolje rezultate ostvaruje nakon TruncatedSVD redukcije sa 700 komponenti, što pokazuje da ovom modelu više odgovara latentna reprezentacija podataka nego selekcija originalnih atributa. Dobijeni rezultat ukazuje da TruncatedSVD uspešno čuva informacije važne za izračunavanje rastojanja između instanci, koje predstavlja osnovu rada KNN klasifikatora.

Nasuprot tome, Multinomial Naive Bayes i Decision Tree najbolje rezultate ostvaruju nakon χ^2 selekcije atributa. Pri tome Decision Tree postiže najbolje performanse već sa 500 odabranih atributa, dok Multinomial Naive Bayes zahteva nešto veći broj atributa (3000). Ovo pokazuje da oba modela imaju korist od uklanjanja manje relevantnih karakteristika iz originalnog skupa podataka.

Posmatrajući izabrane konfiguracije može se uočiti da modeli zahtevaju različit stepen redukcije dimenzionalnosti. Logistic Regression ostvaruje najbolje rezultate sa 300 latentnih komponenti, Decision Tree sa 500 originalnih atributa, KNN sa 700 latentnih komponenti, dok LinearSVC i Multinomial Naive Bayes najbolje performanse postižu sa 3000 odabranih atributa. Ipak, u svim slučajevima broj dimenzija je značajno manji od originalnog skupa koji sadrži 24307 atributa, što potvrđuje da je moguće ostvariti visoke performanse klasifikacije uz značajno smanjenje dimenzionalnosti podataka.

Na osnovu ukupnih rezultata može se zaključiti da su linearni klasifikatori (LinearSVC i Logistic Regression) ostvarili najbolje performanse na posmatranom skupu podataka. LinearSVC predstavlja najbolji model prema F1-score metrici, dok Logistic Regression pokazuje veliku stabilnost i sposobnost očuvanja performansi nakon značajne redukcije dimenzionalnosti. Istovremeno, rezultati potvrđuju da izbor odgovarajuće metode redukcije dimenzionalnosti treba prilagoditi konkretnom klasifikacionom modelu, jer različiti algoritmi najbolje rezultate postižu uz različite reprezentacije podataka i vrednosti hiperparametara.

8.1. ROC analiza najbolji klasifikacionih modela



Pored poređenja modela na osnovu standardnih klasifikacionih metrika, izvršena je i

analiza ROC krivih i AUC vrednosti za najbolje konfiguracije svih primenjenih modela. ROC kriva prikazuje odnos između stope tačno pozitivnih i lažno pozitivnih klasifikacija za različite pragove odlučivanja, dok AUC vrednost predstavlja meru sposobnosti modela da razlikuje dve klase. Veća AUC vrednost ukazuje na bolju sposobnost razlikovanja klasa.


Na osnovu prikazanih ROC krivih može se uočiti da LinearSVC i Logistic Regression ostvaruju najbolje rezultate među posmatranim modelima. Njihove krive su najbliže gornjem levom uglu grafikona, što potvrđuje njihovu dobru sposobnost razlikovanja klasa. Dobri rezultati linearnih modela mogu se objasniti prirodom tekstualnih podataka predstavljenih TF-IDF reprezentacijom, nad kojima linearni klasifikatori uspešno rade čak i u prostorima sa velikim brojem atributa.

Multinomial Naive Bayes takođe ostvaruje dobre rezultate, što je očekivano s obzirom na njegovu čestu primenu u klasifikaciji tekstualnih podataka. Ipak, njegova ROC kriva pokazuje nešto slabiju sposobnost razlikovanja klasa u odnosu na najbolje linearne modele. Decision Tree i KNN ostvaruju slabije rezultate.

Dobijeni rezultati ROC analize u skladu su sa prethodnim evaluacionim metrikama. Linearni modeli pokazuju najbolje performanse na posmatranom skupu podataka, dok modeli zasnovani na lokalnom poređenju instanci i pravilima odlučivanja ostvaruju nešto slabije rezultate.

9. Analiza najboljeg modela

	precision	recall	f1-score	support
-1	0.93	0.87	0.90	387.00
1	0.89	0.94	0.92	442.00
accuracy	0.91	0.91	0.91	0.91
macro avg	0.91	0.90	0.91	829.00
weighted avg	0.91	0.91	0.91	829.00



Za najbolji model izabran je LinearSVC klasifikator, treniran nad reprezentacijom podataka dobijenom primenom χ^2 selekcije atributa sa 3000 odabranih karakteristika. Performanse izabrane konfiguracije dodatno su analizirane pomoću matrice konfuzije i classification report-a, kako bi se detaljnije ispitao način klasifikacije po pojedinačnim klasama.

Matrica konfuzije pokazuje da je model pravilno klasifikovao najveći broj test primera. Od ukupno 387 primera negativne klase, 337 primera je tačno prepoznato, dok je 50 primera pogrešno klasifikovano kao pozitivna klasa. Sa druge strane, od 442 primera pozitivne klase, model je pravilno klasifikovao 415 primera, dok je samo 27 primera označeno kao negativna klasa iako pripada pozitivnoj klasi.

Dobijeni rezultati pokazuju da model posebno uspešno prepoznaje pozitivnu klasu, što potvrđuje visoka vrednost recall metrike od 0.94. To znači da model uspešno pronalazi najveći deo stvarno pozitivnih primera, odnosno da je broj propuštenih pozitivnih klasifikacija mali. Precision vrednost za pozitivnu klasu iznosi 0.89, što ukazuje da se među svim primerima koje je model označio kao pozitivne nalazi relativno mali broj pogrešnih klasifikacija.

Za negativnu klasu model ostvaruje precision vrednost od 0.93 i recall vrednost od 0.87. Ove vrednosti ukazuju da model veoma pouzdano prepoznaje negativne primere kada ih klasifikuje kao takve, ali da određeni broj negativnih primera ipak svrstava u pozitivnu klasu.

Ukupna tačnost modela iznosi 0.91, što znači da je približno 91% svih test primera pravilno klasifikovano. F1-score vrednosti za obe klase su visoke (0.90 za klasu -1 i 0.92 za klasu 1), što potvrđuje dobar balans između precision i recall metrike. Takođe, macro i weighted proseci imaju vrednost približno 0.91, što ukazuje na stabilne performanse modela i pokazuje da rezultati nisu posledica favorizovanja samo jedne klase.

Na osnovu dobijenih rezultata može se zaključiti da LinearSVC model uspešno generalizuje na nepoznate podatke i predstavlja najuspešniji model među ispitanim klasifikacionim algoritmima za dati skup tekstualnih podataka.

Kod LinearSVC modela svakom atributu dodeljuje se koeficijent koji predstavlja njegov uticaj na klasifikacionu odluku. Pozitivne vrednosti koeficijenata ukazuju na veći doprinos klasifikaciji u klasu 1, dok negativne vrednosti ukazuju na veći doprinos klasifikaciji u klasu -1.

Na slikama su prikazane reči sa najvećim pozitivnim i negativnim uticajem na odluku modela. Analizom ovih atributa moguće je uočiti koje karakteristike iz tekstualnih podataka model najviše koristi prilikom razlikovanja dve klase.

	Reč	Koeficijent		Reč	Koeficijent
1500	horse	1.784597	2034	patient	-1.891010
711	cattle	1.756768	48	ad-baby	-1.617320
2168	probiotic	1.613015	2828	treatment	-1.593516
2069	pet	1.562404	543	baby	-1.458196
1740	livestock	1.501905	298	ad-print	-1.426746
284	ad-pet	1.337122	2594	system	-1.426356
474	animal	1.333957	105	ad-commodity	-1.379295
2916	veterinary	1.319431	2611	technology	-1.258499
657	bunny	1.298793	2886	usa	-1.238405
1202	fitness	1.267540	676	cambridge	-1.206565

9.1. Cross validation

Nakon izbora najboljeg modela izvršena je dodatna provera njegove stabilnosti primenom petostruke unakrsne validacije (5-fold cross validation). Za razliku od standardne podele podataka na trening i test skup, gde se performanse procenjuju samo na jednoj podeli, unakrsna validacija omogućava procenu modela kroz više različitih podela podataka.

Petostruka unakrsna validacija izabrana je jer predstavlja dobar kompromis između pouzdanosti procene performansi i računarske zahtevnosti. Pri ovoj proceduri skup podataka se deli na pet delova, pri čemu se svaki deo jednom koristi za validaciju, dok se preostali delovi koriste za treniranje modela. Iako bi se mogla primeniti i 10-struka validacija, takav pristup bi zahtevao dvostruko veći broj treniranja modela, bez značajne potrebe za dodatnim povećanjem pouzdanosti procene.

Rezultati F1-score metrike po pojedinačnim foldovima prikazani su u tabeli. Dobijene vrednosti kretale su se od 0.912 do 0.940, dok je prosečna vrednost iznosila 0.924. Male razlike između rezultata različitih foldova ukazuju na stabilno ponašanje modela i potvrđuju da ostvarene performanse nisu posledica samo jedne podele podataka.

Na osnovu rezultata unakrsne validacije može se zaključiti da izabrani LinearSVC model pokazuje dobru sposobnost generalizacije i zadržava visoke klasifikacione performanse pri različitim podelama trening skupa.

F1-score vrednosti dobijene 5-fold validacijom prikazane su u nastavku:

	Fold	F1-score
0	1	0.911846
1	2	0.932414
2	3	0.920502
3	4	0.917483
4	5	0.939691
5	Prosek	0.924387